



UNIVERSIDADE FEDERAL DO CEARÁ
CENTRO DE TECNOLOGIA
DEPARTAMENTO DE TELEINFORMÁTICA
CURSO DE GRADUAÇÃO EM ENGENHARIA DE COMPUTAÇÃO

DANILO BEZERRA VIEIRA, NATANIEL MARQUES VIANA NETO E THIAGO
SIQUEIRA DE SOUSA

PIPELINE DE AQUISIÇÃO E PRÉ-PROCESSAMENTO MULTIMODAL DE
BIOSSINAIS PARA DETECÇÃO DE FREEZING OF GAIT NA DOENÇA DE
PARKINSON

FORTALEZA

2026

DANILO BEZERRA VIEIRA, NATANIEL MARQUES VIANA NETO E THIAGO
SIQUEIRA DE SOUSA

PIPELINE DE AQUISIÇÃO E PRÉ-PROCESSAMENTO MULTIMODAL DE BÍOSSINAIS
PARA DETECÇÃO DE FREEZING OF GAIT NA DOENÇA DE PARKINSON

Trabalho de graduação das cadeiras TI0093
- AQUISICAO DE BÍOSSINAIS e TI0178 -
PROJETO INTEGRADOR III (2026.1 - T03).

Orientador: Prof. Dr. Victor Hugo Costa
de Albuquerque

FORTALEZA

2026

“A VIDA NÃO É UM MORANGO! Mas você pode preparar o solo, plantar a semente, regá-la todos os dias e no final você não terá um morango, mas vários morangos!”

(Wesllen Albuquerque)

RESUMO

Este trabalho apresenta o desenvolvimento de um pipeline robusto e reproduzível de aquisição e pré-processamento multimodal de bio-sinais para detecção de Freezing of Gait (FoG) na Doença de Parkinson. O estudo utiliza o Multimodal Dataset of Freezing of Gait in Parkinson's Disease (Li et al., 2021), composto por dados de 11 pacientes com registros simultâneos de EEG (28 canais), EMG, ECG, EOG, sensores inerciais (IMU) e condutância da pele. O pipeline foi estruturado em camadas (Bronze e Silver) e organizado em quatro etapas sequenciais: validação estrutural dos dados brutos, resample e alinhamento temporal para 500 Hz, filtragem espectral por modalidade com filtros Butterworth de ordem 4, e normalização Z-score por paciente com tratamento de valores ausentes e clipagem de outliers. A biblioteca MNE-Python foi empregada na leitura e manipulação dos sinais neurofisiológicos. Adicionalmente, são discutidos dois surveys recentes sobre a aplicação de modelos de fundação e modelos de linguagem de grande porte (LLMs) em bio-sinais, identificando limitações como variabilidade individual, escassez de dados rotulados, desafios de representação e riscos de alucinações em contextos clínicos. A validação final do pipeline, realizada por comparação espectral com a referência dos autores originais, resultou em correlação média de 0,789, demonstrando boa fidelidade do processamento desenvolvido. O conjunto de dados normalizado e harmonizado gerado constitui uma base sólida para etapas futuras de extração de características e modelagem computacional voltada à detecção automática de FoG.

Palavras-chave: Doença de Parkinson. Freezing of Gait. Bio-sinais multimodais. Pré-processamento. MNE-Python. Aprendizado de máquina.

ABSTRACT

This work presents the development of a robust and reproducible pipeline for multimodal bio-signal acquisition and preprocessing aimed at detecting Freezing of Gait (FoG) in Parkinson's Disease. The study uses the Multimodal Dataset of Freezing of Gait in Parkinson's Disease (Li et al., 2021), comprising data from 11 patients with simultaneous recordings of EEG (28 channels), EMG, ECG, EOG, inertial sensors (IMU), and skin conductance. The pipeline was structured in layers (Bronze and Silver) and organized into four sequential stages: structural validation of raw data, resampling and temporal alignment to 500 Hz, spectral filtering per modality using 4th-order Butterworth filters, and per-patient Z-score normalization with missing value treatment and outlier clipping. The MNE-Python library was used for reading and processing neurophysiological signals. Additionally, two recent surveys on the application of foundation models and large language models (LLMs) to biosignals are discussed, identifying key limitations such as individual variability, scarcity of labeled data, representation challenges, and hallucination risks in clinical contexts. The final validation of the pipeline, conducted through spectral comparison against the original authors' reference, yielded an average correlation of 0.789, demonstrating satisfactory fidelity of the developed processing workflow. The resulting normalized and harmonized dataset provides a solid foundation for subsequent feature extraction and computational modeling stages targeting automatic FoG detection.

Keywords: Parkinson's Disease. Freezing of Gait. Multimodal biosignals. Preprocessing. MNE-Python. Machine learning.

SUMÁRIO

1	INTRODUÇÃO	7
1.1	Biblioteca MNE-Python	7
1.2	Análise dos Surveys	9
1.2.1	<i>Descrição do Survey 1</i>	9
1.2.2	<i>Descrição do Survey 2</i>	10
1.2.3	<i>Limitações na área de biossinais descritas pelos Survey</i>	11
1.2.3.1	<i>Desafios Inerentes aos Dados e Sinais</i>	11
1.2.3.2	<i>Riscos de Modelos de Linguagem (LLMs)</i>	11
1.2.3.3	<i>Limitações Computacionais e de Implementação</i>	12
1.2.3.4	<i>Padronização, Confiança e Segurança</i>	12
2	METODOLOGIA	13
2.1	Descrição de dataset	13
2.1.1	<i>Descrição dos Biossinais Adquiridos</i>	14
2.2	Processamento Inicial dos Dados Brutos	15
2.3	Análise dos Dados Brutos	16
2.4	Análise dos Dados Filtrados	17
2.4.1	<i>Estrutura dos Arquivos</i>	18
2.4.2	<i>Detecção de Canais Vazios</i>	18
2.4.3	<i>Análise no Domínio do Tempo</i>	19
2.4.4	<i>Histogramas das Distribuições</i>	19
2.4.5	<i>Análise por Boxplots</i>	20
2.4.6	<i>Matrizes de Correlação</i>	20
2.4.7	<i>Comparação entre Tarefas</i>	20
2.4.8	<i>Impacto da Filtragem</i>	21
2.4.9	<i>Disponibilidade dos Rótulos</i>	21
2.4.10	<i>Conclusões</i>	21
2.5	Pré-processamento 1: Validação Estrutural	22
2.5.1	<i>Definição de Constantes e Parâmetros Globais</i>	22
2.5.2	<i>Funções Utilitárias</i>	23
2.5.3	<i>Validação Estrutural dos Dados Brutos</i>	23

2.6	Pré-processamento 2: Resample e Alinhamento Temporal	24
2.6.1	<i>O Problema Técnico</i>	24
2.6.2	<i>Estratégias de Resample</i>	25
2.6.3	<i>Implementação e Validação</i>	25
2.7	Pré-processamento 3: Filtragem dos Sinais	26
2.7.1	<i>Definição dos Filtros por Modalidade</i>	26
2.7.2	<i>Processamento por Paciente e Tarefa</i>	27
2.7.3	<i>Validação Espectral</i>	27
2.8	Pré-processamento 4: Normalização e Comparação com Referência . .	27
2.8.1	<i>Tratamento de NaNs</i>	28
2.8.2	<i>Normalização Z-score por Paciente</i>	28
2.8.3	<i>Clipagem de Outliers</i>	28
2.8.4	<i>Comparação com Referência</i>	29
3	CONCLUSÕES E TRABALHOS FUTUROS	30

1 INTRODUÇÃO

A Doença de Parkinson é uma das desordens neurodegenerativas mais prevalentes no mundo, caracterizada por sintomas motores como tremor, rigidez, bradicinesia e distúrbios da marcha. Entre estes, o Freezing of Gait (FoG), ou “congelamento da marcha”, representa uma das manifestações mais incapacitantes, aumentando significativamente o risco de quedas e comprometendo a qualidade de vida dos pacientes. A detecção precoce e automática do FoG é, portanto, um desafio clínico relevante que tem motivado o desenvolvimento de sistemas baseados em biosinais multimodais.

Este relatório descreve o pipeline completo de aquisição e pré-processamento de dados multimodais coletados em pacientes com Doença de Parkinson durante tarefas de marcha. Foram registrados sinais de Eletroencefalograma (EEG), Eletromiograma (EMG), Eletrocardiograma (ECG), Eletrooculograma (EOG), sensores inerciais (IMU) e condutância da pele, gerando um conjunto rico e heterogêneo de informações neurofisiológicas e cinemáticas.

O objetivo principal deste trabalho foi desenvolver um pipeline robusto, reproduzível e organizado em camadas (Bronze, Silver), capaz de transformar os dados brutos em um conjunto limpo, harmonizado e normalizado, pronto para etapas posteriores de extração de características e modelagem computacional para detecção de Freezing of Gait.

O documento apresenta a descrição do dataset original, detalha cada etapa do pré-processamento (validação estrutural, resample, filtragem, tratamento de NaNs, normalização e clipagem) e inclui a comparação dos resultados obtidos com a referência médica disponibilizada pelos autores do dataset.

1.1 Biblioteca MNE-Python

A biblioteca MNE-Python é uma ferramenta de código aberto desenvolvida para análise e processamento de dados neurofisiológicos. A biblioteca foi projetada principalmente para trabalhar com sinais provenientes de técnicas de neuroimagem funcional, como eletroencefalografia (EEG) e magnetoencefalografia (MEG), além de oferecer suporte para outros tipos de sinais como sEEG, ECoG e fNIRS.

O projeto MNE teve origem a partir de ferramentas desenvolvidas inicialmente em linguagem C para análise de sinais de MEG e EEG. Posteriormente, essas ferramentas foram reimplementadas e ampliadas na linguagem Python, resultando na biblioteca MNE-Python, que

atualmente constitui uma das principais ferramentas utilizadas na comunidade científica para análise de dados neurofisiológicos.

A biblioteca fornece um conjunto abrangente de funcionalidades para manipulação, processamento, análise e visualização de sinais cerebrais. Entre suas principais capacidades está a leitura de diferentes formatos de arquivos utilizados em experimentos de neurociência, permitindo a importação de dados provenientes de diversos equipamentos de aquisição de biossinais.

Uma vez carregados no ambiente de análise, os dados podem ser organizados em estruturas específicas que facilitam sua manipulação. Essas estruturas permitem representar diferentes tipos de informação experimental, incluindo sinais brutos, eventos experimentais e segmentos temporais associados a determinados estímulos.

Outro aspecto importante da biblioteca é o suporte ao pré-processamento dos sinais. Durante a aquisição de dados neurofisiológicos é comum que os sinais contenham ruídos provenientes de diversas fontes, como interferência elétrica do ambiente, atividade muscular ou movimentos do participante. Para lidar com esses problemas, a biblioteca oferece ferramentas para aplicação de filtros digitais, identificação de canais defeituosos e técnicas de remoção de artefatos.

Após o pré-processamento, os dados podem ser segmentados em intervalos temporais associados a eventos específicos ocorridos durante o experimento. Esse processo, conhecido como *epoching*, permite analisar as respostas cerebrais relacionadas a determinados estímulos ou tarefas realizadas pelos participantes.

Além disso, a biblioteca oferece recursos avançados para análise de sinais no domínio do tempo e da frequência. Essas análises permitem identificar padrões de atividade cerebral associados a diferentes processos cognitivos, sendo amplamente utilizadas em estudos de neurociência.

Outro recurso importante do MNE-Python é sua capacidade de visualização dos dados. A biblioteca fornece ferramentas para geração de gráficos e representações visuais que facilitam a interpretação dos sinais, incluindo visualização de canais de EEG, mapas topográficos da atividade cerebral e representações tridimensionais do cérebro.

A biblioteca também oferece suporte à análise espacial da atividade cerebral, permitindo estimar a localização das fontes neurais responsáveis pelos sinais observados nos sensores. Esse tipo de análise é conhecido como problema inverso em neuroimagem e constitui uma das

áreas mais complexas da análise de dados de EEG e MEG.

Além das funcionalidades voltadas para análise de sinais, o MNE-Python também fornece acesso a diversos conjuntos de dados utilizados para demonstração e testes das ferramentas da biblioteca. Esses conjuntos de dados permitem que pesquisadores explorem diferentes técnicas de análise sem a necessidade de realizar experimentos próprios.

Outro aspecto relevante da biblioteca é sua forte integração com o ecossistema científico da linguagem Python. O MNE-Python utiliza bibliotecas amplamente empregadas na computação científica, como NumPy para manipulação de matrizes e vetores, SciPy para métodos numéricos e Matplotlib para visualização de dados. Essa integração permite que pesquisadores desenvolvam pipelines completos de análise de dados utilizando ferramentas amplamente consolidadas na comunidade científica.

Além disso, a documentação oficial da biblioteca é organizada em diferentes seções que auxiliam o aprendizado e a utilização das ferramentas disponíveis. Entre essas seções encontram-se tutoriais que apresentam exemplos completos de análise de dados, exemplos práticos de aplicação das funções da biblioteca, um glossário com definições de termos utilizados na área e uma documentação detalhada da interface de programação da biblioteca.

Dessa forma, a biblioteca MNE-Python se destaca como uma plataforma abrangente para análise de sinais neurofisiológicos, oferecendo ferramentas que permitem desde a manipulação inicial dos dados até análises avançadas utilizadas em pesquisas em neurociência e engenharia biomédica.

1.2 Análise dos Surveys

1.2.1 Descrição do Survey 1

O survey *A Survey of LLMs on Biosignal Applications* discute o uso de modelos de linguagem de grande porte (*Large Language Models* – LLMs) no contexto de aplicações com biosinais. O trabalho parte do cenário de aumento da expectativa de vida e do consequente crescimento da população idosa, destacando que esse contexto amplia riscos de lesões e redução da atividade física, o que torna relevante o desenvolvimento de sistemas capazes de acompanhar indicadores fisiológicos de forma contínua.

Os autores apontam que grande parte das pesquisas em biossensores ainda se concentra em modalidades específicas de sensores, sem explorar de forma ampla o potencial de

integração com LLMs. Como contribuição central, o survey apresenta uma síntese sobre os avanços desses modelos em aplicações com biossinais. Inicialmente, são descritos desafios recorrentes das diferentes modalidades de biossensores e técnicas atuais de aprendizado profundo utilizadas nesse domínio. Em seguida, são analisados sistemas baseados em LLMs já empregados em aplicações de biossinais. Por fim, o artigo identifica desafios em aberto e propõe direções de pesquisa para ampliar a adoção e a efetividade de sistemas com LLMs na área de biossinais.

1.2.2 Descrição do Survey 2

O survey *Foundation Models for Biosignals: A Survey* aborda o uso de modelos de fundação no contexto de biossinais, destacando o crescimento recente dessa abordagem e seu potencial para aplicações em saúde digital.

O trabalho parte da constatação de que, embora modelos de fundação já tenham obtido grande sucesso em áreas como processamento de linguagem natural e visão computacional, sua aplicação em biossinais ainda está em fase de consolidação, carecendo de uma organização mais estruturada das abordagens existentes.

Nesse sentido, o survey organiza o campo em três direções principais. A primeira envolve o desenvolvimento de modelos treinados diretamente a partir de grandes conjuntos de dados de biossinais, considerando etapas como preparação dos dados, representação dos sinais e definição de arquiteturas. A segunda direção trata da adaptação de modelos de séries temporais de propósito geral para o domínio biomédico, explorando estratégias que permitem reutilizar modelos já existentes. A terceira direção analisa o uso de modelos de linguagem de grande porte (LLMs) e suas extensões multimodais, que podem atuar tanto na modelagem dos sinais quanto na integração com informações textuais e clínicas.

Além disso, o survey apresenta uma visão geral das principais modalidades de biossinais, como ECG e EEG, bem como das tarefas mais comuns, incluindo classificação, reconhecimento de padrões e previsão de desfechos clínicos.

Por fim, o artigo discute desafios relevantes para a área, como a necessidade de padronização, a escassez de dados em larga escala e a dificuldade de interpretar os modelos, apontando caminhos para pesquisas futuras.

1.2.3 Limitações na área de biosinais descritas pelos Survey

Os artigos analisados descrevem uma série de limitações que afetam tanto o processamento tradicional de biosinais quanto a aplicação emergente de Modelos de Fundação e LLMs nesta área. As principais limitações podem ser agrupadas nas seguintes categorias:

1.2.3.1 Desafios Inerentes aos Dados e Sinais

- **Qualidade e Ruído:** Os biosinais são altamente suscetíveis a ruídos causados por movimentos do paciente, interferências do ambiente e degradação de sensores. Isso afeta diretamente a precisão das classificações e diagnósticos.
- **Variabilidade Individual:** Fatores como idade, estado mental, tom de pele e anatomia individual criam variações significativas nos sinais (ECG, EEG, PPG), dificultando a generalização dos modelos.
- **Heterogeneidade de Canais e Resolução:** Diferentes dispositivos capturam biosinais com números distintos de canais e taxas de amostragem variadas. Modelos gerais muitas vezes não conseguem processar essas variações sem adaptações complexas
- **Desafios na Representação dos Sinais:** A definição de estratégias eficazes de incorporação (embeddings) ainda é um problema em aberto. Diferentes abordagens, como representações contínuas, segmentação temporal e quantização, podem impactar significativamente o desempenho dos modelos, não havendo ainda um padrão consolidado.

1.2.3.2 Riscos de Modelos de Linguagem (LLMs)

- **Alucinações e Vieses:** LLMs podem gerar saídas tendenciosas ou informações fictícias, o que representa um risco crítico em aplicações médicas de alta responsabilidade.
- **Falta de Contexto Clínico:** A eficácia de modelos na interpretação de sinais pode cair na ausência de contexto clínico detalhado quando comparados com profissionais da área.
- **Dificuldade com Dados Brutos:** LLMs muitas vezes falham em produzir anotações precisas ao lidar diretamente com dados brutos de sensores sem uma etapa de codificação ou reprogramação adequada.

1.2.3.3 Limitações Computacionais e de Implementação

- **Gargalos de Recursos:** O processamento de dados complexos e de alta dimensão exige recursos computacionais e memória substanciais. Isso dificulta a execução em tempo real em dispositivos vestíveis ou plataformas edge.
- **Latência:** A inferência em tempo real é um desafio, onde mesmo pequenos atrasos podem interromper fluxos de trabalho clínicos.
- **Complexidade das Arquiteturas:** O desenvolvimento de modelos capazes de capturar padrões temporais complexos em biosinais frequentemente exige arquiteturas sofisticadas, o que aumenta a dificuldade de treinamento, ajuste e implementação prática.

1.2.3.4 Padronização, Confiança e Segurança

- **Ausência de um pipeline coeso:** Ao contrário do processamento de linguagem natural, a área de biosinais carece de práticas padronizadas para curadoria de dados, arquiteturas de modelo e protocolos de avaliação.
- **Escassez de Dados Rotulados:** O treinamento de modelos de aprendizado profundo exige grandes volumes de dados rotulados de alta qualidade, um processo que é laborioso e caro.
- **Opacidade:** A falta de interpretabilidade dos modelos dificulta a confiança clínica, já que os profissionais de saúde precisam entender os critérios fisiológicos que levaram a uma decisão do modelo. Sem essa confiança, o modelo se assemelha a uma caixa-preta.
- **Privacidade:** A coleta extensiva de dados fisiológicos sensíveis levanta preocupações sobre o vazamento de informações identificáveis do paciente e a vulnerabilidade a ataques adversários que podem enganar os modelos.
- **Escassez de Dados em Larga Escala:** Modelos de fundação dependem de grandes volumes de dados diversos para alcançar boa capacidade de generalização. No entanto, a disponibilidade de bases amplas, padronizadas e acessíveis para biosinais ainda é limitada.
- **Baixa Transferibilidade entre Modalidades:** Modelos treinados em um tipo específico de biosinal frequentemente apresentam dificuldades para generalizar para outras modalidades, como ECG, EEG ou sinais multimodais.

2 METODOLOGIA

A metodologia deste trabalho foi estruturada com o objetivo de desenvolver um pipeline reprodutível de aquisição, organização e pré-processamento de bio-sinais multimodais voltado ao estudo do fenômeno de Freezing of Gait (FoG) na Doença de Parkinson. O desenvolvimento foi realizado a partir do processamento do dataset público Multimodal Dataset of Freezing of Gait in Parkinson's Disease, envolvendo sinais neurofisiológicos e cinemáticos adquiridos de forma simultânea.

O pipeline foi organizado em etapas sequenciais, contemplando ingestão e padronização dos dados brutos, validação estrutural, harmonização temporal entre modalidades com diferentes frequências de amostragem, filtragem espectral específica por tipo de sinal e normalização estatística por paciente. Todas as etapas foram implementadas utilizando ferramentas computacionais da linguagem Python, com destaque para a biblioteca MNE-Python no processamento de sinais neurofisiológicos.

Além do desenvolvimento técnico do pipeline, realizou-se uma análise de literatura baseada em dois artigos do tipo survey relacionados ao uso de modelos de fundação e modelos de linguagem em bio-sinais, permitindo contextualizar os principais desafios atuais da área, como variabilidade individual, escassez de dados rotulados e limitações de generalização de modelos aplicados a sinais biomédicos.

2.1 Descrição de dataset

O presente trabalho foi desenvolvido utilizando o Multimodal Dataset of Freezing of Gait in Parkinson's Disease, disponibilizado publicamente por Li et al. (2021). Este dataset consiste em dados multimodais coletados de 11 pacientes com Doença de Parkinson, sendo que um dos pacientes realizou o protocolo experimental em duas sessões distintas (008-1 e 008-2). Os dados foram adquiridos durante a execução de quatro tarefas padronizadas projetadas para induzir episódios de Freezing of Gait (FoG), incluindo giros de 90 graus, giros de 180 graus e desvio de obstáculos. Durante as tarefas foram registrados simultaneamente sinais de EEG com 28 canais (apenas 25 úteis), EMG, ECG, eletrooculograma (EOG), aceleração e giroscópio em múltiplos segmentos corporais, além de condutância da pele.

O dataset original é fornecido em duas versões principais que serão utilizadas neste estudo. A primeira é a versão de dados crus (raw data), contendo os sinais diretamente adquiridos

dos equipamentos sem processamento. Nela, os sinais de EEG, EMG e ECG foram coletados a 1000 Hz, enquanto os dados de aceleração, giroscópio e condutância da pele foram amostrados a 100 Hz. A segunda versão consiste nos dados filtrados e rotulados (filtered data), processados e anotados pelos autores originais. Nesta versão todos os sinais foram resampleados para 500 Hz, alinhados temporalmente e devidamente rotulados por dois neurologistas experientes a partir de gravações de vídeo sincronizadas. O rótulo binário indica a presença (1) ou ausência (0) de FoG em cada instante temporal.

No pré-processamento realizado pelos autores originais, foram aplicados filtros específicos para cada modalidade de sinal. Os dados de EEG passaram por remoção de artefatos oculares via análise de componentes independentes (ICA), utilizando a média dos eletrodos TP9 e TP10 como referência, filtro passa-banda entre 0,5 e 100 Hz e notch em 50 Hz. Os sinais de EMG foram filtrados com passa-banda de 10 a 500 Hz e notch em 50 Hz. Os dados de aceleração passaram por filtro passa-baixa com frequência de corte em 16 Hz e notch em 50 Hz. Todos os sinais foram ainda normalizados, resultando em arquivos organizados por tarefa no formato task_n.txt, contendo 60 colunas que reúnem timestamp, sinais EEG, EMG/ECG/EOG, dados inerciais e o rótulo de FoG.

Essa dupla disponibilidade de versões permite a comparação entre o processamento realizado pelos pesquisadores originais e as abordagens desenvolvidas no presente trabalho sobre os dados crus.

2.1.1 Descrição dos Biossinais Adquiridos

O dataset multimodal compreende os seguintes biossinais, cada um com aplicações específicas no estudo do Freezing of Gait na Doença de Parkinson:

- **Eletroencefalograma (EEG):** 25 canais segundo o sistema 10-20. Captura a atividade cortical com alta resolução temporal, permitindo investigar modulações neurais relacionadas ao planejamento e controle motor durante a marcha.
- **Eletromiograma (EMG):** músculos tibial anterior (direito e esquerdo) e gastrocnêmio direito. Registra a ativação muscular, auxiliando na análise de padrões de marcha, rigidez e assimetrias motoras.
- **Eletrocardiograma (ECG):** monitora a atividade cardíaca e variações autonômicas associadas ao esforço e estresse durante as tarefas.
- **Eletrooculograma (EOG):** canal IO registra movimentos oculares. Útil para correção de

artefatos no EEG e estudo da coordenação oculomotora.

- **Sensores Inerciais (IMU):** acelerômetros e giroscópios nos tornozelos, cintura e braço. Fornecem dados cinemáticos tridimensionais para quantificação de parâmetros da marcha e detecção de freezing.
- **Condutância da Pele:** reflete atividade autonômica simpática, permitindo correlacionar arousal emocional/fisiológico com episódios de freezing.

2.2 Processamento Inicial dos Dados Brutos

No primeiro estágio de processamento, denominado Camada Bronze, realizou-se a ingestão e padronização dos dados crus do dataset original. O objetivo principal foi transformar os arquivos provenientes de diferentes fontes e formatos em uma única tabela estruturada, consistente e otimizada para as etapas posteriores de análise.

Os dados de EEG, EMG, ECG e EOG foram lidos a partir dos arquivos BrainVision (.vhdr + .eeg) utilizando a biblioteca MNE-Python. Em paralelo, os sinais dos sensores inerciais (acelerômetro e giroscópio) foram carregados dos arquivos .csv correspondentes a cada localização corporal (LShank, RShank, Waist e Arm). Como nem todos os pacientes possuíam todos os sensores e a ordem dos canais de bio-sinais (EMG, ECG e IO) variava entre os indivíduos, foi necessário implementar mecanismos de padronização. Para isso, criou-se um mapeamento específico por paciente que reorganiza corretamente os canais de EMG-RTA, EMG-LTA, EMG-RGS, IO e ECG, preenchendo com NaN os sinais ausentes em determinados sujeitos.

Os sensores inerciais ausentes em alguns pacientes também foram tratados de forma sistemática, gerando colunas completas com valores NaN para manter a consistência estrutural de todo o dataset. Além disso, foi implementado um mecanismo para detecção de sensores “mortos” (aquelas que apresentavam praticamente apenas valores zero), substituindo-os por NaN para evitar dados inválidos. Entretanto, nenhum canal foi classificado como morto após a validação estrutural. O paciente 008, que realizou duas sessões experimentais, foi tratado como duas entidades separadas (008-1 e 008-2) para preservar a integridade de cada gravação.

Por fim, adicionaram-se metadados essenciais (patient_id, session, task_id e timestamp) e garantiu-se um esquema final unificado com todas as colunas esperadas na ordem padronizada. Todos os dados foram convertidos para tipos otimizados (principalmente float32) e o conjunto completo foi salvo em um único arquivo Parquet. Essa camada bronze resultou em

uma tabela unificada, robusta e pronta para as etapas de limpeza, integração temporal e análises subsequentes.

Complementarmente, foi realizada a ingestão da versão já filtrada e rotulada disponibilizada pelos autores originais do dataset. Nessa etapa, os arquivos .txt (um por tarefa por paciente) foram lidos e convertidos para o formato Parquet particionado. Aplicou-se novamente a padronização dos nomes de colunas e da ordem dos canais bioassinais, respeitando as particularidades de cada paciente, especialmente do paciente 008 que possui duas sessões. Metadados de identificação (patient_id, task_id e session) foram incorporados e os dados foram salvos de forma organizada por paciente e tarefa.

Essa versão filtrada, que já contém os sinais processados pelos autores originais (com filtros específicos por modalidade e rótulos de FoG anotados por neurologistas), será utilizada como baseline de comparação para avaliar a qualidade do pré-processamento desenvolvido no presente trabalho a partir dos dados crus.

2.3 Análise dos Dados Brutos

Após a construção da camada Bronze, realizou-se uma análise exploratória detalhada dos dados crus padronizados. O objetivo foi compreender a estrutura, qualidade e características principais do conjunto de dados antes de prosseguir com etapas mais avançadas de pré-processamento e modelagem.

O dataset consolidado possui **3.872.933 observações** (linhas) e **63 colunas**. Cada linha representa um instante temporal amostrado a 1000 Hz, contendo informações multimodais de EEG (25 canais), bioassinais (EMG, ECG, IO) e sensores inerciais (acelerômetros e giroscópios). As colunas de metadados incluem timestamp, patient_id, session e task_id.

A Tabela 1 apresenta um resumo geral do dataset.

Tabela 1 – Visão geral do dataset bruto.

Característica	Valor
Número de amostras	3.872.933
Número de colunas	63
Tipos predominantes	float32 (sinais) e string (metadados)

A ordem dos canais foi padronizada para todos os pacientes, garantindo consistência estrutural. No entanto, devido à natureza heterogênea da aquisição (nem todos os pacientes utilizam todos os sensores), observa-se uma quantidade significativa de valores ausentes (NaN).

Os canais EEG-FZ, EEG-CZ, EEG-PZ e IO estão completamente ausentes em todos os registros, enquanto os sensores de membros inferiores e cintura apresentam valores nulos em aproximadamente 25% a 47% das amostras, conforme esperado pela configuração experimental.

A análise estatística descritiva revelou amplitudes típicas dos sinais de EEG na ordem de microvolts (μV), com valores médios próximos de zero, conforme o esperado para sinais centrados. Os sinais de EMG e ECG apresentam maiores variações, refletindo a natureza fisiológica desses biossinais. Os sensores inerciais (aceleração) mostram magnitudes elevadas, especialmente nos eixos verticais e ântero-posteriores, consistentes com o movimento durante as tarefas de marcha.

A análise de energia média dos sinais (média do quadrado dos valores) confirmou que os sensores inerciais, especialmente os acelerômetros das pernas, concentram a maior parte da potência do sinal, enquanto os canais de EEG apresentam energia muito baixa, como esperado.

Por fim, a coluna de rótulos (`label`) encontra-se completamente vazia nesta versão bruta, conforme previsto, uma vez que a anotação de episódios de Freezing of Gait (FoG) foi realizada apenas na versão filtrada fornecida pelos autores originais. Da mesma forma, a coluna `task_id` encontra-se marcada como “unknown”, pois a segmentação por tarefa ainda não foi integrada.

Em conclusão, os dados brutos apresentam uma estrutura rica e multimodal, porém com desafios típicos de aquisições biomédicas reais: presença de valores ausentes, heterogeneidade entre pacientes e ausência de rótulos. Essas características reforçam a necessidade de um pré-processamento cuidadoso e da integração com a versão filtrada para viabilizar análises subsequentes e o desenvolvimento de modelos de detecção de FoG.

2.4 Análise dos Dados Filtrados

Após a construção da camada Bronze filtrada, foi realizada uma análise exploratória detalhada dos sinais já submetidos ao processo de filtragem e padronização. O objetivo desta etapa foi verificar se o pré-processamento preservou adequadamente as características fisiológicas relevantes dos sinais, ao mesmo tempo em que reduziu ruídos, artefatos e componentes indesejados presentes na versão bruta.

Os dados filtrados estão armazenados em arquivos no formato Parquet, organizados por paciente e, quando necessário, por sessão experimental. Cada arquivo corresponde a uma tarefa específica (*task*) e contém os sinais sincronizados a uma frequência de amostragem de

1000 Hz.

Assim como na versão bruta, cada registro possui 63 colunas, compostas por:

- 25 canais de EEG;
- sinais fisiológicos adicionais, como EMG, ECG e IO;
- sensores inerciais (acelerômetros e giroscópios) posicionados em cintura e membros inferiores;
- metadados: `timestamp`, `patient_id`, `session`, `task_id` e `label`.

Nesta etapa, diferentemente da versão bruta, a coluna `label` já contém as anotações dos episódios de *Freezing of Gait* (FoG), fornecidas pelos autores originais da base de dados. Dessa forma, os dados filtrados representam a versão efetivamente utilizada para treinamento e avaliação dos modelos de classificação.

2.4.1 Estrutura dos Arquivos

Cada paciente possui um conjunto de tarefas experimentais armazenadas individualmente. Para o paciente 008, por exemplo, os dados estão divididos em duas sessões (`OFF_1` e `OFF_2`), exigindo um tratamento específico para consolidação dos arquivos.

Essa organização modular facilita a análise por tarefa e permite investigar variações temporais e contextuais nos sinais.

2.4.2 Detecção de Canais Vazios

Foi implementado um procedimento automático para identificar canais sem medições relevantes. Um sinal foi considerado vazio quando:

- todos os valores eram NaN; ou
- mais de 95% das amostras apresentavam valor praticamente nulo ($|x| < 10^{-8}$).

Essa abordagem permitiu excluir automaticamente canais ausentes dos gráficos e análises estatísticas, evitando interpretações equivocadas.

Os canais EEG-FZ, EEG-CZ, EEG-PZ e IO permaneceram sem dados relevantes em praticamente todos os arquivos, comportamento já observado na camada Bronze bruta.

2.4.3 *Análise no Domínio do Tempo*

A primeira etapa da análise consistiu na inspeção visual dos sinais no domínio do tempo. Para cada canal válido, foram plotadas as primeiras 2000 amostras de quatro tarefas do paciente 001, correspondendo a aproximadamente dois segundos de aquisição.

Essa análise permitiu observar:

- redução significativa do ruído de alta frequência;
- eliminação de tendências lentas (*baseline drift*);
- preservação dos padrões fisiológicos principais;
- continuidade temporal dos sinais;
- ausência de saturação ou descontinuidades artificiais.

Nos canais de EEG, observou-se um comportamento oscilatório suave, com amplitude reduzida e centrada em torno de zero, característica esperada após filtragem passa-faixa e remoção de offset.

Os sinais de EMG mantiveram padrões mais irregulares e impulsivos, refletindo a atividade muscular durante as tarefas motoras.

O ECG apresentou complexos QRS claramente identificáveis, indicando preservação das estruturas fisiológicas relevantes.

Nos sensores inerciais, as oscilações tornaram-se mais regulares, com menor interferência de ruído, evidenciando ciclos de marcha e movimentos corporais.

2.4.4 *Histogramas das Distribuições*

Para cada canal, foram construídos histogramas com 50 bins, permitindo analisar a distribuição estatística das amplitudes.

Os histogramas revelaram que:

- os sinais filtrados tendem a apresentar distribuições aproximadamente simétricas em torno de zero;
- os canais de EEG possuem distribuição estreita, concentrada em amplitudes pequenas;
- EMG e ECG exibem maior dispersão e caudas mais longas;
- sensores inerciais apresentam distribuições mais amplas, refletindo maior amplitude dinâmica.

A centralização das distribuições em torno de zero indica que o processo de filtragem

removeu adequadamente componentes DC e tendências lentas.

2.4.5 *Análise por Boxplots*

Os boxplots permitiram comparar mediana, intervalo interquartil e presença de valores extremos.

Os resultados mostraram:

- medianas próximas de zero na maioria dos canais;
- menor dispersão nos sinais de EEG;
- maior variabilidade em EMG e sensores inerciais;
- ocorrência de outliers fisiologicamente plausíveis.

A presença de outliers não foi interpretada como erro, mas sim como reflexo de eventos reais, como contrações musculares intensas, picos do ECG e movimentos bruscos durante a marcha.

2.4.6 *Matrizes de Correlação*

Foram calculadas matrizes de correlação de Pearson entre todos os canais válidos, utilizando até 2000 amostras por tarefa.

Essa análise possibilitou identificar dependências lineares entre sensores e verificar coerência fisiológica entre sinais.

Os principais padrões observados foram:

- altas correlações entre eixos do mesmo sensor inercial;
- correlação elevada entre sensores posicionados em segmentos corporais próximos;
- correlação moderada entre canais EEG vizinhos;
- baixa correlação entre modalidades distintas (EEG, EMG e inerciais).

Esses resultados indicam que os sinais mantêm relações fisiológicas coerentes após a filtragem, sem introdução de artefatos artificiais de correlação.

2.4.7 *Comparação entre Tarefas*

A visualização simultânea de quatro tarefas para cada canal evidenciou que:

- a escala e a distribuição estatística dos sinais permanecem consistentes entre tarefas;
- variações observadas refletem diferenças reais de movimento e atividade fisiológica;

- não foram detectadas mudanças abruptas decorrentes do pré-processamento.

Essa consistência é essencial para garantir que os modelos de aprendizado de máquina possam generalizar entre diferentes tarefas e pacientes.

2.4.8 Impacto da Filtragem

Em comparação com os dados brutos, os sinais filtrados apresentaram:

- menor ruído de alta frequência;
- remoção de componentes DC;
- maior estabilidade estatística;
- distribuições mais simétricas;
- melhor definição dos padrões fisiológicos relevantes.

Essas melhorias tornam os sinais mais adequados para extração de características, segmentação temporal e treinamento de modelos de detecção de FoG.

2.4.9 Disponibilidade dos Rótulos

A principal diferença estrutural em relação à camada Bronze bruta é a presença da coluna `label`, contendo a anotação temporal dos episódios de FoG.

Essa informação é fundamental para:

- segmentação supervisionada das janelas temporais;
- treinamento de classificadores;
- cálculo de métricas de desempenho;
- análise específica de padrões associados ao congelamento da marcha.

2.4.10 Conclusões

A análise exploratória dos dados filtrados demonstrou que o pipeline de pré-processamento foi bem-sucedido em reduzir ruídos e preservar as características fisiológicas relevantes dos sinais.

Os resultados mostraram que:

- os sinais permanecem centrados em torno de zero;
- as distribuições estatísticas são coerentes com cada modalidade sensorial;
- as correlações entre canais refletem relações fisiológicas esperadas;

- os rótulos de FoG estão disponíveis para aprendizado supervisionado;
- a qualidade geral dos dados é adequada para as etapas subsequentes do projeto.

Em síntese, a camada Bronze filtrada constitui uma base confiável e consistente para o desenvolvimento de modelos de detecção de *Freezing of Gait*, fornecendo sinais limpos, sincronizados e rotulados, prontos para extração de características e modelagem preditiva.

2.5 Pré-processamento 1: Validação Estrutural

O pré-processamento dos dados multimodais foi estruturado em quatro etapas sequenciais, com o objetivo de garantir reprodutibilidade, robustez e rastreabilidade de todas as transformações aplicadas aos sinais brutos. A Parte 1 concentra-se na preparação do ambiente computacional, definição de parâmetros globais e validação estrutural dos dados gerados na camada Bronze.

A aquisição de biossinais em experimentos clínicos, especialmente em pacientes com Doença de Parkinson, resulta frequentemente em conjuntos de dados heterogêneos, com variações na taxa de amostragem entre modalidades (EEG a 1000 Hz versus sensores inerciais a 100 Hz), presença de valores ausentes e diferentes configurações de sensores por indivíduo. Por esse motivo, uma etapa inicial de padronização e validação é essencial para evitar propagação de erros nas etapas subsequentes de resample, filtragem e modelagem.

2.5.1 Definição de Constantes e Parâmetros Globais

Foram estabelecidas constantes fundamentais que regem todo o pipeline de pré-processamento. A escolha da frequência alvo de 500 Hz representa um compromisso entre resolução temporal (necessária para capturar eventos rápidos de Freezing of Gait) e viabilidade computacional. Essa frequência permite o downsampling do EEG (de 1000 Hz para 500 Hz) sem perda significativa de informação espectral relevante (até 100 Hz, conforme filtro aplicado pelos autores originais) e o upsampling dos sinais inerciais (de 100 Hz para 500 Hz) via interpolação, garantindo alinhamento temporal entre todas as modalidades.

A frequência da rede elétrica local (50 Hz) foi utilizada para definir o filtro notch, uma prática padrão na aquisição de EEG para atenuar interferência eletromagnética. Adicionalmente, foi definido um limiar rigoroso para detecção de sensores “mortos” (canais que registram essencialmente ruído de fundo ou zero), baseado na proporção de valores abaixo de 10^{-8} (95%

dos pontos), critério comumente adotado em pipelines de biossinais para identificar problemas de contato ou falhas de hardware.

Os nomes dos canais foram organizados em listas padronizadas (EEG_COLLS, BIO_COLLS e IMU_COLLS), seguindo a nomenclatura 10-20 internacional para EEG e a localização anatômica dos sensores inerciais, garantindo consistência e facilitando a reprodutibilidade.

2.5.2 *Funções Utilitárias*

Foram implementadas funções auxiliares de alto nível, incluindo:

- Detecção automática de sensores mortos;
- Geração de relatórios detalhados de valores ausentes;
- Filtragem eficiente por paciente e sessão;
- Verificação de monotonicidade e integridade temporal.

Essas funções foram projetadas para serem reutilizadas nas etapas seguintes, promovendo um código modular e de fácil manutenção.

2.5.3 *Validação Estrutural dos Dados Brutos*

Antes de qualquer transformação, foi realizada uma validação abrangente do arquivo `full_table.parquet`. Essa etapa é crítica em pipelines de biossinais, pois problemas estruturais (colunas ausentes, timestamps não monotônicos, canais corrompidos) podem comprometer irreversivelmente análises posteriores e interpretações clínicas.

Foram avaliados:

- Presença e integridade das colunas de metadados (`timestamp`, `patient_id`, `session`);
- Distribuição de valores ausentes por canal, distinguindo ausência física de sensor de falhas de aquisição;
- Consistência temporal (monotonicidade do timestamp e detecção de resets);
- Presença de sensores mortos;
- Mapa de disponibilidade de sensores IMU por paciente;
- Inspeção visual de trechos representativos de cada modalidade (EEG, EMG e IMU).

Os resultados indicaram que os dados apresentam a heterogeneidade esperada para uma aquisição multimodal real. Não foram identificados sensores mortos, e os valores ausentes são consistentes com a configuração experimental (ausência de alguns sensores em determinados indivíduos). O timestamp apresentou múltiplos resets, confirmando a necessidade de tratamento

especializado na Parte 2 (alinhamento temporal).

Essa validação inicial confirmou que o conjunto de dados brutos está apto para o prosseguimento do pipeline, garantindo que as etapas subsequentes operem sobre uma base estruturalmente confiável.

2.6 Pré-processamento 2: Resample e Alinhamento Temporal

Uma vez estabelecida a estrutura e validada a integridade dos dados brutos na Parte 1, a segunda etapa do pré-processamento concentra-se em um dos principais desafios técnicos dos conjuntos de dados multimodais: a heterogeneidade nas taxas de amostragem. O arquivo `full_table.parquet` contém sinais de EEG e biossinais (gravados a 1000 Hz) e sinais inerciais IMU (gravados a 100 Hz) alinhados de forma artificial na mesma tabela. Essa incongruência temporal compromete análises subsequentes e o desenvolvimento de modelos de machine learning, que exigem amostras sincronizadas no tempo.

2.6.1 O Problema Técnico

Os sinais foram adquiridos com frequências distintas:

- **EEG e biossinais:** 1000 Hz (1 amostra a cada 1 ms);
- **Sensores inerciais (IMU):** 100 Hz (1 amostra a cada 10 ms).

Ao concatenar tudo em uma única tabela na camada Bronze, o resultado foi uma estrutura onde o EEG mantém sua alta resolução temporal, enquanto o IMU aparece subamostrado, mas com linhas repetidas para preencher o espaço. Isso gera desalinhamento temporal e impede análises integradas entre modalidades.

A solução adotada consiste em harmonizar todas as modalidades para uma frequência alvo comum de 500 Hz. Essa escolha representa um equilíbrio ótimo entre:

- Preservação da informação espectral relevante do EEG (frequências até ~ 100 Hz, conforme pré-processamento original dos autores);
- Redução de dimensionalidade computacional (reduz o volume de dados em 50% em relação ao EEG original);
- Suficiente resolução temporal para capturar eventos rápidos de Freezing of Gait.

2.6.2 Estratégias de Resample

Foram aplicadas duas técnicas distintas conforme a natureza de cada modalidade:

- **EEG e bioassinais:** *Decimação* (downsampling). Reduz-se a taxa de 1000 Hz para 500 Hz selecionando uma amostra a cada duas (fator de decimação = 2). Essa abordagem é simples, computacionalmente eficiente e preserva características temporais sem introduzir artefatos significativos, especialmente quando o sinal será filtrado na etapa seguinte.
- **Sensores inerciais (IMU):** *Interpolação por spline cúbica*. Aumenta-se a taxa de 100 Hz para 500 Hz gerando quatro amostras sintéticas entre cada par de amostras originais (fator de upsampling = 5). A interpolação spline cúbica foi escolhida por produzir curvas suaves e fisicamente plausíveis, evitando descontinuidades que poderiam ser introduzidas por métodos lineares mais simples.

Após o resample individual, realiza-se o **merge temporal** das modalidades em uma única tabela alinhada a 500 Hz, garantindo que cada linha corresponda ao mesmo instante temporal.

Adicionalmente, foram neutralizados os sensores mortos identificados na Parte 1, substituindo seus valores por NaN para evitar contaminação dos modelos subsequentes.

2.6.3 Implementação e Validação

As funções de resample foram implementadas de forma modular, permitindo processamento paciente a paciente. Após a aplicação, foi realizada validação visual comparando os sinais originais com os resampleados, confirmando o alinhamento temporal e a preservação das características principais de cada modalidade.

O resultado final foi salvo em `data/silver/resampled.parquet`, contendo aproximadamente 1.936.470 amostras com todas as modalidades harmonizadas a 500 Hz.

Essa etapa é fundamental para viabilizar análises integradas entre EEG, EMG e sensores inerciais, além de preparar o terreno para a filtragem espectral na Parte 3. A harmonização temporal garante que modelos de machine learning possam explorar de forma eficaz as relações entre as diferentes fontes de sinal.

2.7 Pré-processamento 3: Filtragem dos Sinais

Após o alinhamento temporal realizado na Parte 2, os sinais multimodais encontram-se todos na mesma taxa de amostragem de 500 Hz, mas ainda contêm componentes de ruído não fisiológico que podem comprometer análises posteriores e o desempenho de modelos de detecção de Freezing of Gait. A filtragem surge como etapa essencial para remover essas interferências indesejadas, preservando as características relevantes de cada modalidade.

A necessidade de filtragem em biossinais é bem estabelecida na literatura de neuroengenharia e biomecânica. Cada tipo de sinal apresenta ruídos característicos decorrentes de fontes fisiológicas (movimento muscular, respiração, movimentos oculares) e ambientais (interferência da rede elétrica). A aplicação de filtros digitais permite atenuar essas componentes sem distorcer significativamente a informação de interesse, desde que os parâmetros sejam escolhidos com base nas bandas de frequência fisiológicas conhecidas.

2.7.1 Definição dos Filtros por Modalidade

Foram utilizados filtros Butterworth de ordem 4, conhecidos por apresentarem resposta em frequência maximamente plana na banda passante, minimizando distorções na forma de onda. A aplicação foi realizada com a função `sosfiltfilt`, que garante filtragem de fase zero (forward-backward), preservando o alinhamento temporal entre os canais, aspecto crítico para análises multimodais.

Os parâmetros de corte foram definidos da seguinte forma:

Para o EEG, aplicou-se um filtro passa-banda entre 0,5 Hz e 40 Hz, complementado por um filtro notch em 50 Hz (qualidade $Q=30$). Essa faixa abrange as bandas delta, theta, alpha, beta e parte da gamma baixa, relevantes para estudos de marcha e freezing. Frequências abaixo de 0,5 Hz correspondem principalmente a deriva de linha de base e artefatos lentos, enquanto componentes acima de 40 Hz são dominados por artefatos musculares.

Os sinais de EMG receberam apenas o filtro notch em 50 Hz, preservando o conteúdo de baixa frequência (1–3 Hz) observado na referência médica original. Para o ECG, utilizou-se passa-banda 0,5–40 Hz, removendo deriva respiratória e ruído de alta frequência. O canal de movimento ocular (IO) foi filtrado com passa-baixa de 10 Hz, e os sensores inerciais (IMU) com passa-baixa de 20 Hz, uma vez que movimentos humanos e tremores parkinsonianos concentram energia predominantemente abaixo dessa frequência.

2.7.2 *Processamento por Paciente e Tarefa*

A filtragem foi aplicada individualmente por paciente e tarefa, evitando a propagação de artefatos de borda que ocorreriam caso o filtro fosse executado sobre o conjunto concatenado. Transições abruptas entre sessões de pacientes distintos seriam interpretadas pelo filtro como descontinuidades no sinal, gerando distorções indesejadas.

2.7.3 *Validação Espectral*

Para verificar a eficácia da filtragem, foram gerados espectros de potência (usando o método de Welch) antes e depois do processamento em trechos representativos. Os gráficos confirmaram a atenuação esperada nas bandas de ruído (abaixo de 0,5 Hz e acima de 40 Hz para EEG, por exemplo) e a preservação das frequências de interesse, validando a adequação dos parâmetros escolhidos.

O resultado final foi salvo em `data/silver/filtered.parquet`, mantendo o mesmo número de amostras e estrutura de colunas, agora com sinais limpos e prontos para etapas subsequentes de normalização e análise comparativa com a referência médica.

Essa etapa representa um avanço significativo na qualidade dos dados, reduzindo o impacto de ruídos e aumentando a confiabilidade das características extraídas nas próximas fases do pipeline.

2.8 **Pré-processamento 4: Normalização e Comparação com Referência**

A quarta e última etapa do pipeline de pré-processamento concentra-se na preparação final dos dados para as fases subsequentes de modelagem. Após o resample na Parte 2 e a filtragem na Parte 3, os sinais já se encontram harmonizados em frequência e limpos de ruídos principais, mas ainda requerem tratamento de valores ausentes, normalização e validação contra a referência médica original.

Essa etapa possui duas responsabilidades distintas. A primeira é finalizar o processamento técnico dos sinais: tratamento inteligente de NaNs, normalização Z-score por paciente e clipagem de outliers extremos. A segunda é realizar a comparação sistemática com os arquivos de referência (`task_*.parquet`) produzidos pelo pipeline original dos autores, avaliando se o resultado obtido reproduz adequadamente o comportamento espectral e temporal esperado.

2.8.1 *Tratamento de NaNs*

Os valores ausentes (NaN) podem surgir tanto de sensores fisicamente ausentes em determinados pacientes quanto de falhas pontuais de aquisição. Uma estratégia simples de preenchimento com zero seria inadequada, pois não distingue entre ausência real de sensor e lacunas temporárias no sinal.

Para cada canal e paciente, adotou-se a seguinte abordagem hierárquica:

- Canais completamente ausentes (100% NaN): preenchidos com zero. Nesse caso, a ausência já havia sido documentada na etapa de flags, permitindo que modelos posteriores tratem essa informação explicitamente.
- NaNs isolados no interior do sinal: interpolação linear entre os valores vizinhos válidos.
- NaNs nas bordas do sinal: preenchimento forward/backward com o primeiro ou último valor válido.

O processamento foi realizado paciente a paciente para evitar interpolação incorreta entre dados de indivíduos diferentes. Após essa etapa, não restaram valores ausentes nos canais de sinal.

2.8.2 *Normalização Z-score por Paciente*

A normalização foi realizada por paciente e por canal, transformando cada série temporal para média zero e desvio padrão unitário ($z = (x - \text{média}) / \text{desvio}$). Essa abordagem é fundamental em dados multimodais, pois diferentes pacientes podem apresentar amplitudes basais distintas devido a variações fisiológicas, impedância de eletrodos ou posicionamento de sensores.

A normalização global sobre todo o dataset seria inadequada, equivalendo a comparar notas de provas com dificuldades distintas sem ajuste. Armazenaram-se os parâmetros de média e desvio padrão por paciente e canal em arquivo separado, permitindo a reversão da normalização quando necessário.

2.8.3 *Clipagem de Outliers*

Após a normalização Z-score, valores extremos (acima de $\pm 5\sigma$) foram clipados. Essa técnica remove artefatos residuais que sobreviveram à filtragem, como piscadas intensas ou contatos momentâneos ruins de eletrodos, sem afetar significativamente a distribuição dos dados

fisiológicos. Aproximadamente 0,135% das amostras foram clipadas, proporção consistente com a presença esperada de artefatos em aquisições reais.

2.8.4 Comparação com Referência

A validação final consistiu na comparação espectral e temporal com os arquivos de referência da camada bronze filtrada. Foram avaliados canais representativos (EEG-C3, EEG-FP1, EMG-RTA, LShank-ACCX e Waist-ACCZ) utilizando correlação de espectros de potência (método de Welch), estatísticas de amplitude e séries temporais.

Os resultados indicaram reprodução de boa qualidade na maioria dos canais. O EMG-RTA apresentou excelente concordância (média $\approx 0,94$), seguido pelos canais de EEG (média entre 0,82 e 0,84). O sinal de IMU do quadril (Waist-ACCZ) também mostrou boa correlação (média $\approx 0,85$). O principal ponto de atenção foi o LShank-ACCX, com correlação média mais baixa ($\approx 0,44$), sugerindo maior sensibilidade desse sensor a variações de posicionamento ou reamostragem.

A correlação espectral média geral foi de 0,789, caracterizando o pipeline como razoavelmente fiel à referência. A aparência visual “achatada” dos sinais normalizados é esperada e correta, decorrente da transformação Z-score, enquanto a forma espectral e o conteúdo fisiológico foram preservados.

O arquivo final `normalized.parquet` está pronto para extração de features e modelagem. Os parâmetros de normalização e as flags de sensores ausentes foram salvos separadamente, garantindo rastreabilidade completa do pipeline.

Essa etapa conclui o pré-processamento, transformando os dados brutos heterogêneos em um conjunto limpo, normalizado e validado, adequado para as análises subsequentes.

3 CONCLUSÕES E TRABALHOS FUTUROS

Este trabalho apresentou o desenvolvimento de um pipeline completo e estruturado de aquisição e pré-processamento multimodal de bio-sinais para detecção de Freezing of Gait na Doença de Parkinson. A partir dos dados brutos do Multimodal Dataset of Freezing of Gait in Parkinson's Disease, foram aplicadas quatro etapas sequenciais de processamento: validação estrutural, resample e alinhamento temporal, filtragem espectral e normalização, organizadas segundo uma arquitetura em camadas (Bronze e Silver) que garante rastreabilidade, reprodutibilidade e modularidade ao longo de todo o fluxo de trabalho.

A etapa de validação estrutural confirmou a integridade do conjunto de dados brutos, identificando a heterogeneidade esperada entre pacientes e a ausência de sensores mortos, além de documentar sistematicamente os valores ausentes e as variações de configuração por indivíduo. O resample para 500 Hz harmonizou com sucesso as modalidades adquiridas em taxas distintas (1000 Hz para EEG e bio-sinais; 100 Hz para sensores inerciais), utilizando decimação para o downsampling e interpolação spline cúbica para o upsampling, garantindo alinhamento temporal entre todos os canais. A filtragem espectral, realizada com filtros Butterworth de fase zero por modalidade e por paciente, removeu eficazmente ruídos não fisiológicos, como a interferência da rede elétrica em 50 Hz e artefatos de movimento, preservando os componentes fisiológicos relevantes para a detecção de FoG. Por fim, a normalização Z-score por paciente e canal, combinada ao tratamento hierárquico de NaNs e à clipagem de outliers extremos, produziu um conjunto de dados limpo, padronizado e comparável entre indivíduos.

A validação comparativa com a referência dos autores originais resultou em correlação espectral média de 0,789, com destaque para os sinais de EMG-RTA (média 0,94) e canais de EEG (médias entre 0,82 e 0,84). O canal LShank-ACCX apresentou correlação mais baixa (média 0,44), evidenciando maior sensibilidade desse sensor a variações de posicionamento e reamostragem, aspecto que deve ser investigado em etapas futuras. De forma geral, os resultados indicam que o pipeline desenvolvido reproduz com boa fidelidade o processamento de referência, validando as escolhas metodológicas adotadas.

Complementarmente, a análise de dois surveys recentes sobre o uso de modelos de fundação e LLMs em bio-sinais destacou desafios relevantes da área, como a variabilidade individual dos sinais, a escassez de grandes bases rotuladas, as dificuldades de representação e os riscos inerentes à aplicação de LLMs em contextos clínicos, incluindo alucinações e falta de contexto fisiológico. Esses aspectos reforçam a importância de pipelines de pré-processamento

bem estruturados como o aqui desenvolvido, que constituem a base indispensável para qualquer abordagem de aprendizado de máquina nesse domínio.

Como trabalhos futuros, destacam-se: a extração de características no domínio do tempo e da frequência a partir do conjunto normalizado gerado; o desenvolvimento e avaliação de modelos de aprendizado de máquina e aprendizado profundo para detecção automática de episódios de FoG; a investigação de estratégias para lidar com o desbalanceamento de classes inerente à baixa prevalência de eventos de FoG; a análise da contribuição individual de cada modalidade de biossinal para a detecção do fenômeno; e a exploração de modelos multimodais capazes de integrar as diferentes fontes de sinal de forma conjunta. A expansão do pipeline para incluir extração automática de features e a integração com modelos de fundação especializados em biossinais representam direções promissoras para o avanço do estado da arte na detecção de Freezing of Gait.

REFERÊNCIAS

GRAMFORT, Alexandre; LUESSI, Martin; LARSON, Eric; ENGEMANN, Denis A.; STROHMEIER, Daniel; BRODBECK, Christian; GOJ, Roman; JAS, Mainak; BROOKS, Teon; PARKKONEN, Lauri; HÄMÄLÄINEN, Matti. **MEG and EEG data analysis with MNE-Python**. *Frontiers in Neuroscience*, v. 7, p. 267, 2013.

LI, Hantao. **Multimodal Dataset of Freezing of Gait in Parkinson's Disease**. Mendeley Data, version 3, 2021. Disponível em: <<https://data.mendeley.com/datasets/r8gmbtv7w2/3>>. Acesso em: 11 maio 2026.

LI, Hantao. **Raw Data: Multimodal Dataset of Freezing of Gait in Parkinson's Disease**. Mendeley Data, version 1, 2021. Disponível em: <<https://data.mendeley.com/datasets/t8j8v4hnm4/1>>. Acesso em: 11 maio 2026.

NETO, Nataniel Marques Viana; DE SOUSA, Thiago Siqueira; VIEIRA, Danilo Bezerra. **TI093-biosignals-acquisition**. GitHub, 2026. Disponível em: <<https://github.com/thiago-sqr/TI093-biosignals-acquisition.git>>. Acesso em: 11 maio 2026.

ZHANG, Wei; YANG, Zhuokun; LI, Hantao; HUANG, Debin; WANG, Lipeng; WEI, Yanzhao; MA, Lin; FENG, Huanhuan; PAN, Jing; CHAN, Piu; GUO, Yuzhu. **Multimodal Data for the Detection of Freezing of Gait in Parkinson's Disease**. *Scientific Data*, v. 9, n. 1, p. 1–10, 2022. Disponível em: <<https://www.nature.com/articles/s41597-022-01713-8>>. Acesso em: 11 maio 2026.